


FACULTAD REGIONAL DE CÓRDOBA



Ingeniería en Sistemas de Información

Ciencia de Datos

Trabajo Práctico Integrador - Entrega 1

Grupo 3

Integrantes

- Canaan, Abigail Sara - 85860
- Cimatti, Benjamin - 94312
- Morales Demaria, Lucio - 94289
- Pasolli, Lucas - 94250
- Steffolani, Nicolas - 94196
- Tejeda, Emanuel Jesus - 401000
- Testa, Octavio - 94177

Docentes

- Gualpa, Mariano Martín
- Calle, Manuel Rodrigo
- Rustan, Silvina

Curso: 5k3

Año: 2026



Índice

Índice	2
Descripción del set de datos	3
Variables del set de datos	3
Información que se podría obtener del set de datos	5
Plan de proyecto	6
Eventos Scrum	6
Roles del equipo	7
Backlog del proyecto	7
Plan de iteraciones	8
Descripción plan de iteraciones	9

Descripción del set de datos

El presente trabajo utiliza el **F1 Racing Dataset**, publicado en Kaggle, que ofrece una vista a nivel de vuelta de carreras de Fórmula 1 correspondientes a las temporadas 2021, 2022 y 2023. El dataset resulta de la integración de tres fuentes distintas:

- **Ergast API:** base de datos histórica de Fórmula 1 (resultados de carrera, pilotos, vueltas, escuderías, circuitos).
- **FastF1:** librería de Python que provee telemetría y datos de sesión oficiales de la F1 (compuestos de neumáticos, stints, tiempos por vuelta).
- **FastF1 Weather API:** variables meteorológicas registradas durante cada sesión (temperatura, humedad, lluvia, viento).

Tamaño y cobertura: el dataset contiene 69.230 registros y 29 variables. Cubre 3 temporadas (2021–2023), 27 circuitos distintos, 29 pilotos y 10 escuderías, con vueltas numeradas dentro de cada carrera (ronda 1 a 22 según el calendario de cada año).

Objetivo del análisis: se propone estudiar los factores que inciden en el rendimiento de un piloto vuelta a vuelta (uso y desgaste de neumáticos, condiciones climáticas, posición en pista) y evaluar la factibilidad de predecir el tiempo de vuelta (en milisegundos) mediante técnicas de aprendizaje automático.

Variables del set de datos

Variable	Tipo	Descripción
raceId	int64	Identificador único de la carrera (clave Ergast que combina temporada y circuito).
year	int64	Año / temporada de la carrera (2021, 2022 o 2023).
round	int64	Número de fecha (ronda) dentro del calendario de esa temporada (1 a 22).
circuitId	int64	Identificador único del circuito (Ergast).
name	string	Nombre del circuito donde se disputa la carrera (27 circuitos distintos).
lap	int64	Número de vuelta dentro de la carrera.

Variable	Tipo	Descripción
LapNumber	int64	Número de vuelta según FastF1.
time	string	Tiempo de vuelta en formato texto mm:ss.mmm.
milliseconds	int64	Tiempo de vuelta en milisegundos. Variable objetivo (target).
Piloto, escudería y resultado		
driverId	int64	Identificador único del piloto (Ergast).
code	string	Código de 3 letras del piloto (por ej. VER, HAM).
Driver	string	Código de 3 letras del piloto según FastF1.
constructorId	int64	Identificador de la escudería / constructor (10 equipos distintos).
grid	string	Posición de largada en la parrilla de salida.
position_x	int64	Posición del piloto al completar esa vuelta (orden de carrera, 1 a 20).
position_y	float64	Posición final del piloto al término de la carrera.
statusId	int64	Código numérico Ergast del estado final del piloto en la carrera.
status	string	Descripción textual del estado final del piloto en la carrera.
Neumáticos		
Compound	string	Compuesto de neumático utilizado (SOFT, MEDIUM, HARD, etc.).
TyreLife	float64	Antigüedad del neumático, en vueltas recorridas (1 a 69).
FreshTyre	bool	Indica si el neumático era nuevo (True) o usado (False) al inicio del stint.

Variable	Tipo	Descripción
Stint	float64	Número de tramo (stint) con un mismo juego de neumáticos (1 a 8).
Variables meteorológicas		
AirTemp	float64	Temperatura del aire durante la vuelta, en grados Celsius.
TrackTemp	float64	Temperatura de la superficie de la pista, en grados Celsius.
Humidity	float64	Humedad relativa del ambiente, en porcentaje (%).
Pressure	float64	Presión atmosférica, en hectopascales (hPa).
Rainfall	float64	Indicador binario de lluvia durante la vuelta (0 = no, 1 = sí).
WindSpeed	float64	Velocidad del viento, en m/s.
WindDirection	float64	Dirección del viento, en grados (0° a 360°).

Información que se podría obtener del set de datos

A partir de la estructura y el contenido del dataset, se identifican las siguientes líneas de análisis posibles:

- **Predicción del tiempo de vuelta:** estimar la variable **“milliseconds”** en función de las condiciones de neumático, clima y posición en carrera.
- **Análisis de estrategia de neumáticos:** impacto del compuesto (Compound) y del desgaste (TyreLife) sobre el ritmo de carrera, e identificación de la ventana óptima de cambio de neumáticos.
- **Influencia de las condiciones climáticas:** efecto de la temperatura de pista, la humedad y la lluvia sobre la degradación del neumático y el tiempo de vuelta.
- **Comparación de rendimiento entre pilotos y escuderías:** consistencia de ritmo de vuelta, evolución a lo largo de una carrera y entre temporadas.

- **Detección de vueltas atípicas:** identificación de outliers vinculados a incidentes de carrera (banderas amarillas, safety car, accidentes).
- **Análisis por circuito:** comparación del comportamiento del tiempo de vuelta y de la estrategia de neumáticos entre los 27 circuitos presentes en el dataset.

Plan de proyecto

Eventos Scrum

Para asegurar el correcto desarrollo del proyecto bajo el marco de trabajo Data-Driven Scrum, establecemos los siguientes eventos:

- **Sprint Planning:** Al inicio de cada sprint, definiremos los objetivos, las tareas y las prioridades de análisis. En este espacio, seleccionaremos las hipótesis de datos que guiarán nuestro trabajo para asegurar que cada esfuerzo aporte valor al objetivo predictivo del proyecto.
- **Daily Meeting (Asíncrona):** Mantendremos una comunicación constante a través de nuestros canales digitales. Cada integrante del equipo enviará un informe detallando sus avances, tareas planificadas y posibles bloqueos. El Scrum Master consolidará y leerá estos reportes para garantizar que el equipo esté alineado y resolver cualquier impedimento de forma ágil sin interrumpir el flujo de análisis.
- **Sprint Review:** Al finalizar cada sprint, presentaremos los avances logrados y los descubrimientos realizados sobre el dataset. En esta instancia, validaremos los resultados obtenidos y la evolución del modelo frente a los objetivos planteados originalmente.
- **Sprint Retrospective:** Generaremos un espacio de mejora continua donde, como equipo, reflexionaremos sobre el trabajo realizado. El propósito es identificar lecciones aprendidas durante la experimentación con los datos y proponer ajustes metodológicos para el siguiente sprint.

Roles del equipo

Product Owner (PO)	• Cimatti, Benjamin
Scrum Master	• Steffolani, Nicolas
Developers	• Canaan, Abigail Sara • Morales Demaria, Lucio • Pasolli, Lucas • Tejeda, Emanuel Jesus • Testa, Octavio

Backlog del proyecto

ID	Ítem	Descripción	Estimación
DDS-01	Comprensión del dataset	Analizar estructura, variables y granularidad	S
DDS-02	Calidad de datos	Detectar nulos, duplicados e inconsistencias	S
DDS-03	Análisis del tiempo de vuelta	Estudiar distribución y valores atípicos	M
DDS-04	Análisis de neumáticos	Estudiar Compound, TyreLife, Stint y FreshTyre	M
DDS-05	Análisis meteorológico	Analizar influencia del clima	M
DDS-06	Análisis de variables	Determinar variables potencialmente relevantes	M
DDS-07	Preparación del dataset	Transformar variables para modelado	M
DDS-08	Modelo baseline	Construir primera aproximación predictiva	M

DDS-09	Experimentación	Comparar diferentes modelos	L
DDS-10	Evaluación	Comparar métricas y errores	M
DDS-11	Interpretación	Analizar resultados obtenidos	M
DDS-12	Presentación	Elaborar informe y exposición	S

La estimación se realizará mediante T-Shirt sizing (S, M, L), ya que Data-Driven Scrum propone utilizar estimaciones de alto nivel en proyectos de Data Science, donde resulta difícil predecir con precisión cuánto tiempo requerirá una investigación exploratoria.

Plan de iteraciones

Nro. de iteración	Descripción	Ítems del Backlog	Entrega
1	Comprender	DDS-01	1ra Entrega
2	Calidad	DDS-02	2da Entrega
3	Rendimiento	DDS-03, DDS-06	2da Entrega
4	Neumáticos	DDS-04	2da Entrega
5	Clima	DDS-05	2da Entrega
6	Preparación del dataset	DDS-07	2da Entrega
7	Modelado	DDS-08, DDS-09 (modelo baseline + experimentación)	3ra Entrega
8	Evaluación e Interpretación	DDS-10, DDS-11	3ra Entrega
9	Presentación final	DDS-12	4ta Entrega

Descripción plan de iteraciones

ITERACIÓN 1: COMPRENDER ¿Qué información contiene el dataset y es adecuada para nuestro problema?

- Carga de fuentes y evaluación de estructura.
- Análisis de tipos de datos y granularidad.
- Detección inicial de valores faltantes y duplicados absolutos.

ITERACIÓN 2: CALIDAD ¿La calidad de los datos permite utilizarlos directamente para el análisis?

- Resolución de nulos y columnas redundantes.
- Manejo de inconsistencias y valores extremos.
- Prevención de data leakage para el modelado.

ITERACIÓN 3: RENDIMIENTO ¿Qué variables parecen estar relacionadas con el tiempo de vuelta?

- Visualización mediante histogramas, boxplots y scatter plots.
- Cálculo de correlaciones y comparación por compuesto/circuito.
- Selección de variables potencialmente relevantes para el modelo.

ITERACIÓN 4: NEUMÁTICOS ¿El compuesto y el desgaste del neumático influyen en el tiempo de vuelta?

- Análisis de Compound, TyreLife y FreshTyre.
- Estudio del efecto del Stint sobre el ritmo de vuelta.
- Identificación de patrones de degradación del neumático.

ITERACIÓN 5: CLIMA ¿Las condiciones meteorológicas aportan información para explicar el tiempo de vuelta?

- Análisis de AirTemp, TrackTemp y Humidity.
- Evaluación del impacto de Rainfall sobre el ritmo de carrera.
- Estudio de Pressure, WindSpeed y WindDirection.

ITERACIÓN 6: PREPARACIÓN DEL DATASET ¿Cómo debe transformarse el dataset para que pueda ser utilizado por un modelo?

- Tratamiento final de nulos según la estrategia definida.
- Codificación de variables categóricas (Compound, status, etc.).
- Selección y escalado de las columnas del dataset objetivo.

ITERACIÓN 7: MODELADO ¿Qué algoritmo y configuración ofrecen el mejor desempeño predictivo?

- Entrenamiento de un modelo baseline (ej. regresión lineal).
- Experimentación con modelos alternativos (árboles, ensembles).



ITERACIÓN 8: EVALUACIÓN E INTERPRETACIÓN ¿Qué tan preciso es el modelo y qué conocimiento aporta sobre el fenómeno?

- Cálculo de métricas de error (MAE, RMSE) sobre el conjunto de test.
- Análisis de importancia de variables (feature importance).
- Interpretación de resultados en el contexto del dominio (F1).

ITERACIÓN 9: PRESENTACIÓN FINAL ¿Cómo comunicamos el trabajo realizado de forma efectiva?

- Construcción del relato mediante data storytelling.
- Elaboración del informe final y los materiales de exposición.
- Ensayo grupal de la presentación ante la clase.